



بسم الله الرحمن الرحيم



دانشگاه صنعتی اصفهان

دانشکده مهندسی برق و کامپیوتر

تشخیص بیماری COVID-19 با استفاده از تصاویر سی تی اسکن و شبکه عصبی  
کانولوشن مبتنی بر معماری DenseNet121

گزارش پروژه کارشناسی

مریم سعیدمهر

استاد راهنما

دکتر شادرخ سماوی

شهریور ۱۴۰۰

# فهرست مطالب

عنوان	صفحه
فهرست مطالب	چهار
فهرست تصاویر	شش
چکیده	۱
فصل اول : مقدمه	۲
۱-۱ موضوع پژوهش و مسئله	۲
۲-۱ اهمیت و ضرورت	۳
۳-۱ اهداف تحقیق	۳
۴-۱ ساختار گزارش	۳
فصل دوم : پیش زمینه و مروری بر مطالعات انجام شده	۴
۱-۲ شبکه های عصبی	۵
۲-۲ بخش بندی معنایی	۸
۳-۲ شبکه های عصبی کانولوشن	۸
۲-۳-۱ عملیات کانولوشن	۹
۲-۳-۲ Average Pooling عملیات	۱۰
۴-۲ اولین معماری شبکه کانولوشنی	۱۱
۵-۲ لایه تماماً متصل	۱۱
۶-۲ تابع هزینه	۱۲
۷-۲ پیشینه تحقیقات انجام شده	۱۳
فصل سوم : داده ها و روش حل مسئله	۱۵
۱-۳ چارچوب کاری پروژه	۱۵
۲-۳ داده های مورد استفاده در پروژه	۱۶
۳-۳ بررسی مدل پیشنهادی برای حل مسئله	۱۷
۴-۳ شبکه DenseNet121	۱۸
فصل چهارم : تجزیه و تحلیل نتایج	۲۱
۱-۴ معرفی معیارهای مختلف	۲۱

۲۲ ..... شبیه‌سازی مدل ۲-۴

۲۲ ..... ۱-۲-۴ نمایش دیاگرام دقت و خطای شبکه روی داده‌ها

۲۳ ..... ۲-۲-۴ طبقه‌بندی و ارزیابی

۲۴ ..... فصل پنجم: نتیجه‌گیری و جمع‌بندی

۲۵ ..... مراجع

## فهرست تصاویر

۷	۱-۲ شبکه عصبی Feed Forward
۸	۲-۲ نمونه‌ی بخش‌بندی معنایی در ماشین‌های خودران
۱۰	۳-۲ عملیات کانولوشن
۱۰	۴-۲ عملیات Average Pooling با گام ۲
۱۱	۵-۲ معماری پایه‌ی شبکه‌ی عصبی کانولوشنی
۱۲	۶-۲ عملیات لایه‌های تماماً متصل که بعد از آخرین لایه Pooling قرار می‌گیرد
۱۶	۱-۳ چارچوب کاری پروژه
۱۷	۳-۳ نمونه تصویر در دیتاست با برچسب $-ve$
۱۷	۲-۳ نمونه تصویر در دیتاست با برچسب $+ve$
۱۹	۴-۳ ساختار یک بلوک متراکم از DenseNet
۱۹	۵-۳ ساختار یک بلوک متراکم از DenseNet با نرخ رشد $k$
۲۰	۶-۳ فرایند ادغام طی انتشار رو به جلو
۲۰	۷-۳ شبکه DenseNet با سه بلوک متراکم
۲۲	۱-۴ نمایش دیاگرام دقت شبکه روی داده‌ها
۲۳	۲-۴ ماتریس درهم‌ریختگی و کلاس‌بندی

## چکیده

بیماری کوید<sup>۱</sup> یک بیماری عفونی است که توسط ویروس کرونا ایجاد شده است. این بیماری، طبق گزارش سازمان بهداشت جهانی (WHO)<sup>۲</sup> ۲۱۵ کشور و سرزمین در سراسر جهان را درگیر کرده و تأثیرات مخربی بر سلامتی و رفاه جهانی گذاشته است. یک گام حیاتی در مبارزه با کرونا، غربالگری بیماران آلوده است. در مطالعات اولیه مشخص شد که در تصاویر سی تی اسکن ریه<sup>۳</sup> بیماران، ناهنجاری وجود دارد که مشخصه افراد آلوده به کرونا است و ناشی از عفونت در اثر سندرم حاد تنفسی ویروس کرونا است به این ترتیب عکسبرداری از ریه با استفاده از سی تی اسکن یکی از این رویکردهای غربالگری کلیدی به حساب می آید. حوزه پردازش تصاویر پزشکی بازه وسیعی از کاربردها را در برمی گیرد. نگرش های گوناگون دسته بندی و خوشه بندی مبتنی بر یادگیری ماشین به جهت بهبود دقت در غربالگری بیماری ها ارائه شده است. در سال های اخیر روشی مبتنی بر شبکه های عصبی کانولوشن<sup>۴</sup> معرفی شده که مهم ترین مزیت آن تواناییش در استخراج ویژگی های تصاویر به صورت خودکار با استفاده از مفهوم یادگیری عمیق است. در همین راستا برای کمک به پزشکان و کادر درمان در دقت و سرعت غربالگری و فراهم ساختن موجبات تسریع درمان بیماران آلوده به کرونا در این پروژه با استفاده از اجرای شبکه عصبی کانولوشن با معماری DenseNet121 بر روی دیتاست SARS-CoV-2 CT Scan Dataset با ۲۴۸۲ تصویر سی تی اسکن ریه در دو کلاس Covid و Noncovid، دقت 92.96%، حساسیت 91% و تشخیص 94% به دست آمد.

**واژه های کلیدی:** ۱- شبکه عصبی عمیق ۲- پردازش تصویر ۳- تصاویر پزشکی ۴- یادگیری عمیق ۵- شبکه عصبی کانولوشنی عمیق ۶- تصاویر سی تی اسکن ۷- کوید ۱۹.

---

<sup>1</sup> COVID-19

<sup>2</sup> World Health Organization

<sup>3</sup> Computed Tomography images

<sup>4</sup> Convolutional Neural Network

# فصل اول

## مقدمه

کویید ۱۹ بیماری اپیدمیک و خطرناک قرن حاضر است که اولین بار در ووهان چین مشاهده شد و تا کنون جان بیش از چهار میلیون و پانصد هزار نفر را گرفته است. بیماری کویید ۱۹ اثرات منفی بر روی دستگاه تنفسی دارد و با استفاده از تصاویر سی تی اسکن شدت عفونت قابل تشخیص است اما تشخیص به موقع آن می تواند شانس فرد را در بهبودی و جلوگیری از سرایت به دیگران افزایش دهد.

### ۱-۱ موضوع پژوهش و مسئله

کویید ۱۹ اولین بار در نوامبر ۲۰۱۹ در شهر ووهان ، استان هوبی چین گزارش شده است. یک ماه بعد ، سازمان بهداشت جهانی (WHO) اعلام کرد که این ویروس با علائم بالینی سرفه، تب و التهاب ریه بروز می کند. اگرچه کویید ۱۹ در چین پدیدار شد اما اکنون در بسیاری از کشورهای دیگر جهان نیز شناسایی شده است. [۱] در ۳۰ ژانویه سال ۲۰۲۰، WHO این بیماری همه گیر را به عنوان مورد اورژانس بهداشت عمومی اعلام کرد. این نه تنها به دلیل گسترش سریع فرد به فرد بود، بلکه به دلیل اینکه بیشتر افرادی که به آن آلوده می شوند برای بار دوم هم مصون نیستند. سازمان بهداشت جهانی در ۱۱ مارس ۲۰۲۰، هنگامی که تعداد موارد تایید شده به بیش از ۴۰۰۰ کشته در ۱۱۸۰۰۰ مبتلا رسید اعلام کرد که شیوع کویید ۱۹ به عنوان یک بیماری همه گیر مطرح



است. تظاهرات بالینی کوید ۱۹ پیچیده است و می‌تواند به حالت تب، سرفه و سردرد شدید و در نهایت ذات‌الریه ظاهر شود. چندین روش برای تشخیص کوید ۱۹ شامل تست اسیدنوکلیتیک اسید<sup>۱</sup>، عکس رادیوگرافی قفسه سینه و سی‌تی‌اسکن ریه وجود دارد. از تست اسیدنوکلیتیک اسید برای شناسایی توالی اسیدنوکلیتیک خاص و گونه‌های ارگانسیم استفاده می‌شود، عمدتاً ویروس یا باکتری‌هایی باعث ایجاد بیماری در خون، بافت یا ادرار می‌شوند. اگرچه کیت‌های تشخیصی نقش مهمی در تشخیص کوید ۱۹ دارند، عکس رادیولوژی قفسه سینه و سی‌تی‌اسکن ریه یکی از موثرترین و کارآمدترین روش‌ها برای تشخیص شدن و درجه التهاب ریه است که احتمالاً با ویروس کوید ۱۹ آلوده شده است [۲].

## ۱-۲ اهمیت و ضرورت

در چند ماه اخیر تحقیقات زیادی بر روی تصاویر سی‌تی‌اسکن ریه جهت تشخیص زودهنگام بیماری ذات‌الریه به عنوان علامت مهم ابتلا به کرونا ویروس صورت گرفته است تا بتوان بدون دخالت رادیولوژیست، این ویروس را با استفاده از روش‌های پردازش تصویر تشخیص داد. لزوم تشخیص زودهنگام بیماری و غربالگری جهت تسریع درمان این بیماری سبب استفاده از شبکه عصبی کانولوشن به عنوان زیرشاخه‌ای از تکنیک‌های یادگیری عمیق شده است.

## ۱-۳ اهداف تحقیق

در این پروژه، تلاش شده است تحقیقی نسبتاً کامل و روشی بهینه در جهت تشخیص بیماری کوید ۱۹ با استفاده از شبکه عصبی کانولوشن و معماری DenseNet121 داشته باشیم.

## ۱-۴ ساختار گزارش

در فصل دوم به مروری بر مفاهیم پایه مورد نیاز برای این پروژه، در فصل سوم به سابقه و پیشینه تحقیقات انجام شده، در فصل چهارم به بررسی منابع، داده‌ها و چهارچوب کاری پروژه خواهیم پرداخت. در نهایت، فصل پنجم به معرفی و بررسی کامل مدل پیشنهادی برای حل مسئله و فصل پایانی ارزیابی و جمع‌بندی کلی پروژه را دربرمی‌گیرد.

---

<sup>1</sup>NAT

## فصل دوم

### پیش‌زمینه و مروری بر مطالعات انجام‌شده

در سال ۲۰۰۶ میلادی روش یادگیری ساختار یافته عمیق یا به طور معمول یادگیری عمیق یا یادگیری سلسله مراتبی به عنوان یک شاخه جدید از علم بینایی ماشین پدیدار شد. در طی سال‌های گذشته، تکنیک‌های تعمیم‌یافته از روش یادگیری عمیق، تحت تاثیر طیف وسیعی از شاخه‌های علم پردازش اطلاعات و سیگنال مانند هوش مصنوعی، یادگیری ماشین و همچنین پوشش رسانه‌ای بوده است. این فرآیند در بسیاری از حالات شبکه‌های عصبی برای بهبود رفتارهایی از ماشین مانند تشخیص گفتار، بینایی کامپیوتر و پردازش زبان طبیعی استفاده می‌کند. یادگیری عمیق زیر مجموعه‌ای از یادگیری ماشین به حساب می‌آید که در آن بر اساس یادگیری چند سطحی در یک ساختار سلسله مراتبی از ویژگی‌ها یا مفاهیم سطوح بالاتر مفاهیم و ویژگی‌های سطوح پایین‌تر تعریف شده و همچنین مفاهیم سطح پایین نیز می‌توانند به تعریف مفاهیم سطح بالاتر کمک کنند. به زبان ساده‌تر هدف اصلی یادگیری عمیق استخراج ویژگی‌ها به صورت هوشمند طی چند مرحله یادگیری است. به طور خلاصه یادگیری عمیق را می‌توان به این صورت معرفی کرد: یادگیری عمیق شاخه‌ای از یادگیری ماشین و مجموعه‌ای از الگوریتم‌ها است که تلاش می‌کنند مفاهیم انتزاعی سطح بالا را با استفاده از یادگیری در سطوح و لایه‌های مختلف مدل کند. یادگیری عمیق نقطه مقابل مفهومی به نام یادگیری کم عمق است. یادگیری کم عمق همان روش‌های معروف یادگیری ماشین است که در اغلب روش‌های پردازشی استفاده می‌شوند. یادگیری عمیق اغلب

از شبکه های عصبی برای بهبود رفتارهای ماشین مانند تشخیص گفتار، بینایی کامپیوتر و پردازش زبان طبیعی استفاده می‌کند. اولین مراحل معرفی و بکارگیری یادگیری عمیق در حوزه پردازش تصویر و با عنوان شبکه‌های عصبی کانولوشنی توسط LeCun در سال ۱۹۹۸ انجام شد. در این روش سعی شد که عمل یادگیری و درک تصویر مانند مغز انسان و به صورت چند سطحی انجام شود.

## ۱-۲ شبکه‌های عصبی

یادگیری عمیق یکی از شاخه های علم یادگیری ماشین می‌باشد که امروزه بسیار مورد توجه قرار گرفته است. در حقیقت در این دسته از الگوریتم ها از یک شبکه‌ی عصبی عمیق به عنوان هوش مصنوعی استفاده می‌شود که قادر است با دقت بالا یاد بگیرد و در مواردی که هرگز از قبل آنها را ندیده است پیش بینی دقیقی انجام دهد. در حالت کلی شبکه‌های عصبی می‌توانند به دو صورت نظارت‌شده<sup>۱</sup> یا نظارت‌نشده<sup>۲</sup> آموزش ببینند. در یادگیری نظارت‌شده داده‌های در دسترس، همگی دارای یک برچسب صحیح می‌باشند. برچسب صحیح در مسائل مختلف می‌تواند چیزهای مختلفی باشد. مثلاً در مبحث طبقه‌بندی تصاویر این برچسب نام طبقه‌بندی‌های مختلف می‌باشد که می‌تواند عکس سگ یا گربه باشد. یا در زمینه‌ی سگ‌متی‌شن تصاویر این برچسب درحقیقت یک تصویر هم اندازه با تصویر ورودی می‌باشد که در آن قسمت‌های مختلف تصویر به یک رنگ خاص درآمده است که در حقیقت هر رنگ نشان دهنده‌ی یک کلاس سگ‌متی‌شن می‌باشد. در یادگیری نظارت‌نشده ما برچسب صحیح نداریم و مدل باید با همان دیتای خام یادگیری را انجام دهد. به عنوان مثال می‌توان به مدل‌های خودرمن‌نگار اشاره کرد که در یک کاربرد خاص برای فشرده سازی عکس به کار می‌روند و همچنین خارج کردن عکس از حالت فشرده و بازسازی مجدد عکس از تصویر فشرده شده. در تمامی مثال‌های ذکر شده به تابع هزینه‌ای تعریف می‌شود که براساس آن عملیات یادگیری انجام می‌شود. تابع هزینه مدل را برای پیش‌بینی‌های اشتباه در طول فرایند یادگیری تنبیه می‌کند و باعث می‌شود که مقدار جریمه افزایش یابد. در نهایت هدف نهایی شبکه عصبی مینیم کردن این تابع هزینه می‌باشد که این کار را از طریق تغییر دادن وزن‌های خود انجام می‌دهد. در حالت یادگیری نظارت‌شده خروجی مسئله‌ی ما می‌تواند به دو حالت باشد: خروجی پیوسته و گسسته. در حالت پیوسته که اصطلاحاً به آن رگرسیون گفته می‌شود هدف ما تخمین یک مقدار پیوسته است. برای مثال می‌خواهیم قیمت یک خانه را با داشتن پارامترهای مختلفی از قبیل مساحت، تعداد اتاق، سال ساخت خانه و ... تخمین بزنیم. مشخص است که خروجی این مسئله هر مقداری می‌تواند به خود بگیرد پس خروجی پیوسته و مسئله رگرسیون می‌باشد. در حالت گسسته خروجی ما مقادیر گسسته دارد که به این نوع مسائل طبقه‌بندی گفته می‌شود. برای

<sup>1</sup>Supervised

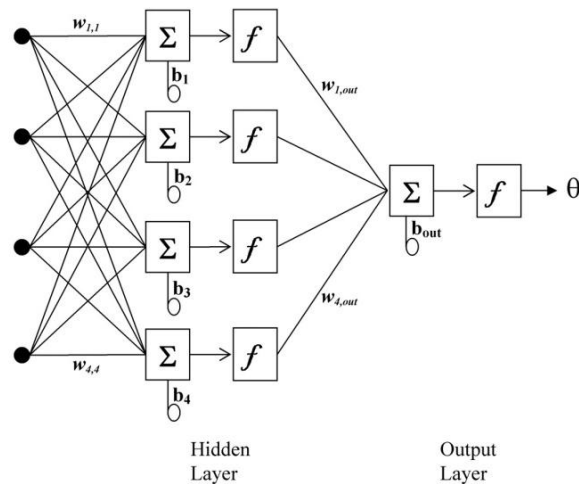
<sup>2</sup>Unsupervised

مثال اگر بخواهیم عکس سگ را از گربه تشخیص دهیم ورودی مسئله‌ی ما یک تصویر است و خروجی آن فقط مقادیر ۰ یا ۱ که به ترتیب به معنی سگ و گربه است می‌باشد. البته تعداد دسته‌های خروجی می‌تواند خیلی بیشتر هم باشد. در مسئله‌ی تشخیص کرونا- مثبت بودن یا نبودن، خروجی ما یک مقدار گسسته می‌باشد که یا مقدار ۰ است یا ۱ که به این معنی است که آن تصویر ورودی مربوط به بیماری با نتیجه‌ی کرونا- مثبت است یا خیر پس دسته‌بندی تصاویر سی‌تی‌اسکن را می‌توان از نوع مسائل طبقه‌بندی دانست. در حالت کلی شبکه‌ی عصبی را می‌توان برای هر دو نوع مسائل رگرسیون و طبقه‌بندی به کار گرفت که این موضوع را با تعیین تابع فعالسازی در لایه‌ی آخر می‌توان انجام داد که در ادامه به آن بیشتر می‌پردازیم.

در حالت کلی شبکه‌ی عصبی را می‌توان به صورت یک نگاشت غیرخطی ورودی به خروجی مدل کرد که در آن در هر لایه روی ورودی اعمالی انجام می‌شود و سپس به دنبال آن یک تابع فعالسازی روی آن اعمال می‌شود. هر لایه نیز برای خود وزن‌های به خصوص و تابع فعالسازی خاص خود را دارد. در هر مرحله خروجی هر لایه به ورودی لایه‌ی بعد داده می‌شود و این روند ادامه پیدا می‌کند تا خروجی حاصل شود. (البته در بسیاری از حالات لایه‌ها کاملاً به صورت خطی پشت هم قرار نمی‌گیرند و حالت بحث شده ساده‌ترین شکل ممکن است) برای هر شبکه‌ی عصبی به طور کلی می‌توان رابطه‌ی ورودی هر لایه و خروجی آن را به شکل روابط زیر مدل کرد.

$$\begin{aligned} Z^{(1)} &= W^{(1)}Z^{(0)} + b_1 \\ A^{(1)} &= F_1\left(Z^{(1)}\right) \\ &\vdots \\ Z^{(i)} &= W^{(i)}Z^{(i-1)} + b_i \\ A^{(i)} &= F_i\left(Z^{(i)}\right) \end{aligned} \quad (1-2)$$

که در عبارات بالا  $Z$  نماد خروجی لایه پس از ضرب شدن در وزن آن لایه است و  $A$  خروجی لایه پس از اعمال تابع فعال سازی می‌باشد.  $Z^{(0)}$  نیز برابر با بردار ویژگی ورودی می‌باشد که همان ویژگی‌های خام می‌باشد و در ابتدا روی آن تابع فعالسازی استفاده نمی‌شود.



شکل ۲-۱: شبکه عصبی Feed Forward

در هر لایه از شبکه بعد از ضرب کردن ورودی‌ها در وزن‌های آن لایه یک تابع فعال‌ساز روی آن اعمال می‌کنیم که وظیفه‌ی آن غیر خطی کردن مدل است که باعث افزوده شدن پیچیدگی به مدل می‌شود و مدل قادر می‌شود یک نگاشت غیرخطی بین ورودی و خروجی پیدا کند. در صورتی که در لایه‌های شبکه تابع فعال‌ساز استفاده نشود افزودن به تعداد لایه‌ها هیچ تاثیری ندارد و مدل پیچیده تر نمی‌شود و تنها می‌توان یک ترکیب خطی از ورودی‌ها را ایجاد کند. در جدول زیر معروف‌ترین توابع فعال‌ساز آورده شده است. در کاربردها و شبکه‌های مختلف ممکن است به تناسب موقعیت و کاربرد توابع فعال‌سازی متفاوتی استفاده شود که به چند مورد آن اشاره می‌کنیم.

جدول ۲-۱: توابع فعال‌ساز مشهور

Relu	Sigmoid	tanh
$F(x) = \max(0, x)$	$F(x) = \frac{1}{1+e^{-x}}$	$F(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

در لایه‌های میانی شبکه به طور معمول از تابع Relu به عنوان فعال‌ساز استفاده می‌شود چرا که این تابع از لحاظ بار محاسباتی بسیار بهینه است و در اکثر مسائل نتایج خوبی را نمایش داده است. برای مسائل طبقه بندی در لایه آخر از تابع Sigmoid استفاده می‌شود چون این تابع هر مقداری را بین ۰ و ۱ نگاشت می‌کند که برای مسائلی مثل طبقه بندی که لایه‌ی آخر نشان‌دهنده‌ی احتمال هر کلاس است، واجب است (از آنجا که احتمال باید عددی بین ۰ و ۱ باشد). تابع tanh نیز تا حد زیادی شباهت به Sigmoid دارد فقط مقادیر را بین ۱ و

۱ - نگاشت می‌کند و یکی از مواردی که این تابع نتایج خوبی در آن داشته است در لایه‌ی آخر شبکه‌های مولد خصمانه است.

## ۲-۲ بخش‌بندی معنایی

بخش‌بندی معنایی<sup>۱</sup> تصاویر یکی از زمینه‌های بسیار پرکاربرد در پردازش تصاویر می‌باشد. هدف از بخش‌بندی معنایی تصویر اختصاص دادن یک کلاس به تک‌تک پیکسل‌های موجود در تصویر است. برای مثال در بحث ماشین‌های خودران ما علاقه‌مند هستیم برای تک‌تک تصاویر ورودی به ماشین عملیات بخش‌بندی را روی آن انجام دهیم تا مشخص کنیم هر پیکسل داخل عکس به چه کلاسی تعلق دارد مانند: کلاس ماشین، جاده، درخت، انسان و ... .

بخش‌بندی تصاویر مدت زیادی است که تبدیل به یکی از حوزه‌های مورد علاقه پژوهشگران هوش مصنوعی شده است و تاکنون روش‌های بسیار زیادی برای آن ارائه شده است که بطور کلی شامل روش‌های کلاسیک در پردازش تصویر و روش‌های مبتنی بر یادگیری ماشین است.

در کار پیش رو هدف بخش‌بندی باینری برای تصاویر CT Scan ریه می‌باشد تا بتوانیم آلودگی یا عدم آلودگی برای تک‌تک پیکسل‌های عکس را مورد بررسی قرار دهیم که برای این هدف یک روش مبتنی بر یادگیری ماشین و شبکه‌های عصبی عمیق ارائه شده است که در ادامه به تفصیل به آن می‌پردازیم.



شکل ۲-۲: نمونه‌ی بخش‌بندی معنایی در ماشین‌های خودران

## ۳-۲ شبکه‌های عصبی کانولوشن

مدل کردن پردازش‌هایی که انسان قادر به انجام آن بر روی تصاویر است (برای مثال تشخیص هویت با استفاده از حس بینایی) با یک برنامه‌ی کامپیوتری آرزوی چندین ساله محققین حوزه‌ی تصویر بوده است. با معرفی

<sup>1</sup> Semantic Segmentation


شبکه‌های عمیق تصور می‌شد که این مشکلات با استفاده از این روش جدید قابل حل شدن هستند. ولی یک مشکل بزرگ در مسیر استفاده‌ی شبکه‌های عمیق برای پردازش تصاویر، هزینه‌ی محاسباتی این روش برای استفاده بر روی حجم زیاد داده‌ای که یک تصویر را تشکیل می‌دهد است. در حالت متداول شبکه‌های عمیق برای محاسبه‌ی مقدار خروجی هر نورون، خروجی تمام نورون‌های لایه‌ی قبل استفاده می‌شود و شیوه‌ی استفاده از خروجی هر یک از نورون‌های قبلی با یک پارامتر مشخص می‌شود. یک تصویر با رزولوشن نسبتاً کم، برای مثال  $256 \times 256$  را می‌توان یک بردار به طول 65536 در نظر گرفت که با توجه به مطالب گفته شده می‌توان درک کرد که حرکت داده‌ای با این حجم در لایه‌های یک شبکه‌ی عمیق می‌تواند به چه اندازه از نظر محاسباتی سخت و سنگین باشد.

برای عبور از این مانع شبکه‌ای جدید با محوریت پردازش داده‌های تصویری (یا به شکل کلی‌تر پردازش سیگنال) طراحی شد و این الگوریتم جدید را شبکه‌های عصبی کانولوشنی<sup>۱</sup> نامگذاری کردند. تفاوت عمده‌ی این طرح جدید در این نکته بود که بهتر است برای محاسبه‌ی خروجی هر نورون از خروجی تمام نورون‌های لایه‌ی قبل استفاده نشود بلکه فقط از یک همسایگی محدود از نورون‌های همسایه استفاده شود در نتیجه هزینه‌ی محاسباتی برای پردازش و مهم‌تر از آن تعداد پارامترهای مدل کاهش می‌ابد. هر لایه از این شبکه (در ساده‌ترین حالت) با یک کرنل تعریف می‌شود که مقادیر آن به عنوان پارامترهایی قابل تغییر فرض می‌شوند که شبکه در فرایند یادگیری آنها را تنظیم می‌کند. ورودی هر لایه یک تصویر (یا به عبارتی دیگر نقشه‌ی ویژگی) و خروجی آن نیز به همین ترتیب است ولی لزوماً رزولوشن این دو یکی نیست. این کرنل بر روی تک‌تک پیکسل‌های تصویر اعمال می‌شود و تصویر خروجی تولید می‌شود. به این عملیات فیلتر کردن در شبکه‌ی عصبی کانولوشن می‌گویند. یک عملیات دیگر که در این نوع از شبکه‌ها از آن زیاد استفاده می‌شود Max pooling نام دارد. هر کدام از این دو عملیات در ادامه توضیح داده می‌شود.

## ۲-۳-۱ عملیات کانولوشن

عملیات کانولوشن به طور کلی برای استخراج ویژگی از یک تصویر به کار می‌رود. با تغییر این فیلتر می‌توان ویژگی‌های متفاوت از تصویر استخراج کرد. در شبکه‌های عصبی کانولوشن پارامترهای این فیلتر در حین آموزش شبکه تعیین می‌شود به طوری که تابع هزینه را کاهش دهد. فیلترهایی که در شبکه به دست می‌آید الزاماً برای ما مفهوم خاصی ندارد و برای ما قابل درک نیست.


<sup>۱</sup> Convolutional Neural Networks



شکل ۲-۳: عملیات کانولوشن

## ۲-۳-۲ عملیات Average Pooling

این لایه به طور معمول بعد از چند لایه کانولوشن می‌آید و کاربرد آن برای کاهش سایز Feature Map ها است. همچنین با این کار ما از Overfitting شبکه‌ی عصبی جلوگیری می‌کنیم. در این عملیات با توجه به سایز پنجره‌ای که انتخاب می‌کنیم برای مثال ۴، از بین هر ۴ پیکسل در پنجره‌ی  $2 \times 2$  میانگین پیکسل‌های داخل پنجره را نگه می‌داریم و بقیه‌ی پیکسل‌ها را دور می‌ریزیم. به این ترتیب سایز Feature Map ما نصف می‌شود. یک نتیجه‌ی بسیار مهم دیگر برای این عملیات کاهش چشمگیر حجم محاسبات در شبکه می‌باشد چرا که با نصف شدن اندازه‌ی Feature Map ها انجام عملیات کانولوشن روی آنها نیز روی مساحت کمتری صورت می‌گیرد و به این ترتیب در کل محاسبات بهینه‌تر می‌شوند. البته به جای Average Pooling می‌توان از همان عملیات کانولوشن ولی با گام<sup>۱</sup> بیشتر از یک استفاده کرد که همان نتیجه را می‌دهد و سایز Feature Map ها را نصف می‌کند و دقت بهتری هم دارد ولی بار محاسباتی آن بیشتر می‌شود. علاوه بر Average Pooling انواع دیگری از Pooling هم وجود دارد به نام‌های Max Pooling, Min Pooling، ... .

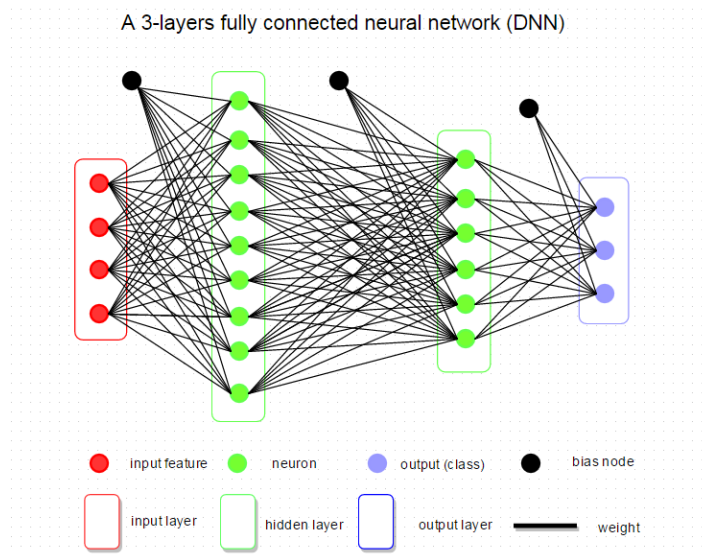


شکل ۲-۴: عملیات Average Pooling با گام ۲

<sup>۱</sup>Stride







شکل ۲-۶: عملیات لایه‌های تماماً متصل که بعد از آخرین لایه Pooling قرار می‌گیرد

لایه‌های تماماً متصل همانند همتایان خود در شبکه‌های عصبی مصنوعی سنتی عمل می‌کنند و تقریباً 90% پارامترهای یک شبکه عصبی کانولوشنی را شامل می‌شوند. لایه تماماً متصل به ما اجازه می‌دهد تا نتیجه شبکه را در قالب یک بردار با اندازه مشخص ارائه کنیم. ما می‌توانیم از این بردار برای دسته‌بندی تصاویر استفاده کنیم و یا اینکه از آن جهت ادامه پردازش‌های بعدی بهره ببریم.

تغییر ساختار لایه‌های تماماً متصل رایج نیست، اما یک نمونه در روش Transferred learning انجام شد [۴] که در آن پارامترهای فراگرفته شده توسط ImageNet حفظ شده اما لایه تماماً متصل آخر با دو لایه تماماً متصل جایگزین شد تا شبکه با این کار بتواند با فعالیت‌های تشخیص بینایی جدید انطباق پیدا کند.

مشکل بزرگ این نوع لایه‌ها این است که دارای تعداد بسیار زیادی پارامتر هستند. که نتیجه این امر هزینه پردازشی بسیار بالایی است که در زمان آموزش بایستی صرف شود. بنابراین یک روش که معمولاً بکاربرده می‌شود و نتایج رضایت بخشی نیز دارد این است که یا کلاً این لایه‌ها حذف شوند و یا تعداد اتصالات در این لایه‌ها توسط روش‌هایی کاهش یابد. بعنوان مثال GoogLeNet یک شبکه عمیق و گسترده را طراحی کرد که در آن هزینه محاسباتی ثابت نگه داشته شده است. این کار با تعویض معماری تماماً متصل با معماری بطور پراکنده متصل صورت گرفت. [۵]

## ۲-۶ تابع هزینه

در تمامی مسائل یادگیری ماشین از جمله مسائل مربوط به یادگیری عمیق و شبکه‌های عصبی ما نیاز به یک معیار داریم تا بتوانیم مدل را بر اساس آن آموزش دهیم. برای همین یک تابع هزینه برای مسئله تعریف می‌شود

که هدف الگوریتم یادگیری ماشین ما این است که تابع هزینه‌ی ما را به حداقل برساند. یا به عبارتی پارامترهای الگوریتم به طریقی تنظیم شوند تا بتوانند تابع هزینه را مینیمم کند و یا دقت را ماکسیمم. اگر مسئله‌ی ما رگرسیون باشد که در نتیجه خروجی پیوسته می‌شود. تابع هزینه‌ی MSE مناسب‌ترین گزینه است که به شکل زیر تعریف می‌شود:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (2-2)$$

که در آن  $n$  تعداد داده‌های آموزشی و  $y_i$  نماد برجسب صحیح داده و  $\hat{y}_i$  مقدار پیش‌بینی شده توسط الگوریتم ما است. اگر مسئله ما از نوع طبقه‌بندی باشد تابع هزینه‌ی آن Cross Entropy می‌باشد که به صورت زیر است:

$$BCE = -\frac{1}{N} \sum_{i=0}^N y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i) \quad (3-2)$$

که پارامترهای آن دقیقاً مانند مسئله‌ی قبل می‌باشد. باید توجه داشت برای مسئله‌ی طبقه‌بندی نمی‌توان از تابع MSE استفاده کرد به این دلیل که اگر از این تابع استفاده شود ما با یک تابع غیر محدب روبرو می‌شویم که در این صورت نمی‌توان تضمین کرد که جواب ما بهینه‌ی سراسری باشد و ممکن است فقط یک بهینه‌ی محلی باشد.

## ۲-۲ پیشینه تحقیقات انجام شده

در تحقیق Bullock و همکاران [۶] یک مرور کلی درباره برنامه اخیر ارائه می‌دهند. برای اولین بار برای تشخیص کوید ۱۹ از تصویربرداری پزشکی CXR و CT استفاده کردند، اگرچه آزمایشات PCR مزایای بسیاری نسبت به CXR و CT دارند. در تحقیق Tao و همکاران [۷] معتقد بودند که در آزمایشات بالینی حمل نمونه از بیماران ضروری است، در حالی که در عکس قفسه سینه یا سی‌تی‌اسکن با توجه به اینکه ماشین‌آلات حتی در مناطق دورافتاده به راحتی قابل دسترسی هستند، تشخیص را آسان می‌نماید.

در یک مطالعه اخیر، تصاویر عکس قفسه سینه یا سی‌تی‌اسکن از ۹ بیمار مبتلا به کوید ۱۹ توسط دو متخصص رادیولوژی مورد بررسی قرار گرفتند، فاصله ارزیابی مکاتبات یافته‌های غیرطبیعی در اشعه X با موارد موجود در تصاویر سی‌تی‌اسکن، نسبت به افراد سالم در یافته‌های رادیوگرافی اولیه برای سارس 82.4% و برای مارس 83.6% بود. در حالی که در موارد کوید ۱۹ میزان 33% است. در مقابل، تصویر درگیری دو برابر ریه را در ۸ مورد از ۹ بیمار نشان دادند. به عبارت دیگر، ممکن است اشعه ایکس بهترین روش برای تشخیص کوید ۱۹ نباشد، اما اشکال کار آنها تعداد کم عکس‌ها و نمونه تست‌ها بود [۸]. اما اطلاعات به دست آمده در [۹] نشان می‌دهد اثربخشی تشخیصی سی‌تی‌اسکن از عکس‌های رادیوگرافی قفسه سینه بیشتر است. این بدین معنی است

که منبع تصویربرداری اولیه برای تشخیص کوید ۱۹ در مناطقی با شیوع زیاد باید سی‌تی‌اسکن باشد. در تحقیق Zhao و همکاران [۱۰] از یک شبکه عصبی کانولوشن با معماری DenseNet برای پردازش تصاویر سی‌تی‌اسکن استفاده کردند. جهت ارزیابی از دیتاست سی‌تی‌اسکن ریه افراد مبتلا به کوید ۱۹، شامل ۴۷۰ تصویر سی‌تی‌اسکن (۲۷۵ عکس افراد مبتلا به کوید ۱۹ و ۱۹۵ افراد سالم) استفاده کردند و به دقت 84.7% و امتیاز F1 85.3% در طبقه‌بندی باینری به دو کلاس COVID و Non COVID دست یافتند.

در تحقیق Loey و همکاران [۱۱] از ۵ معماری متفاوت شبکه عصبی کانولوشن شامل AlexNet, VGG16, ResNet50 و VGG19, GoogleNet برای پردازش تصاویر سی‌تی‌اسکن استفاده کردند. جهت ارزیابی از دیتاست سی‌تی‌اسکن ریه افراد مبتلا به کوید ۱۹، شامل ۷۴۶ تصویر سی‌تی‌اسکن (۳۴۹ عکس افراد مبتلا به کوید ۱۹ و ۳۹۷ افراد سالم) استفاده کردند و نتیجه حاصله برتری معماری ResNet50 و دقت 82.91% را به دنبال داشت. در تحقیق Gozes و همکاران [۱۲] از شبکه دو بُعدی و سه بُعدی یادگیری عمیق برای پردازش تصاویر سی‌تی‌اسکن استفاده کردند. جهت ارزیابی از دیتاست مجموعه داده‌های کنترل چین و بیماران آلوده استفاده کردن و به دقت 99.6%، حساسیت 98.2% و تشخیص 92.2% در طبقه‌بندی باینری به دو کلاس COVID و Non COVID دست یافتند.

در تحقیق Wu و همکاران [۱۳] از یادگیری عمیق و تلفیق تکنیک‌های طبقه‌بندی و بخش‌بندی برای پردازش تصاویر سی‌تی‌اسکن استفاده کردند. جهت ارزیابی از دیتاست بزرگ سی‌تی‌اسکن ریه، شامل ۱۱۴۱۶۷ تصویر سی‌تی‌اسکن (۴۰۰ عکس افراد مبتلا به کوید ۱۹ و ۳۵۰ فرد بیمار غیر کوید ۱۹) استفاده کردند و سیستم JCS برای طبقه‌بندی حساسیت متوسط 95%، تشخیص 93% و امتیاز 78.3% را در مجموعه آزمون تقسیم‌بندی به دست آورد.

من در این پروژه از کار Ahuja و همکاران [۱۴] استفاده کرده‌ام. آن‌ها با استفاده از یادگیری عمیق مبتنی بر انتقال از تصاویر سی‌تی‌اسکن که به سه سطح تجزیه شده‌اند، تشخیص داده می‌شود. یک مدل تشخیص سه مرحله‌ای برای بهبود دقت تشخیص ارائه داده‌اند و مراحل شامل: مرحله اول افزایش داده‌ها، مرحله دوم ایجاد مدل CNN با پیش‌آموزش و مرحله سوم محلی‌سازی ناهنجاری در تصاویر سی‌تی‌اسکن است. در این تحقیق از معماری‌های شناخته شده شبکه عصبی کانولوشن با پیش‌آموزش مانند SqueezeNet, ResNet101 و ResNet50 استفاده شده است. این محققان 70% تصاویر را برای آموزش شبکه و 30% تصاویر را برای اعتبارسنجی شبکه در نظر گرفته‌اند. نتیجه ارزیابی تجربی تایید می‌کند که مدل مبتنی بر یادگیری انتقال از پیش‌آموزش دیده ResNet18 دقت طبقه‌بندی بهتری را ارائه می‌دهد.

## فصل سوم

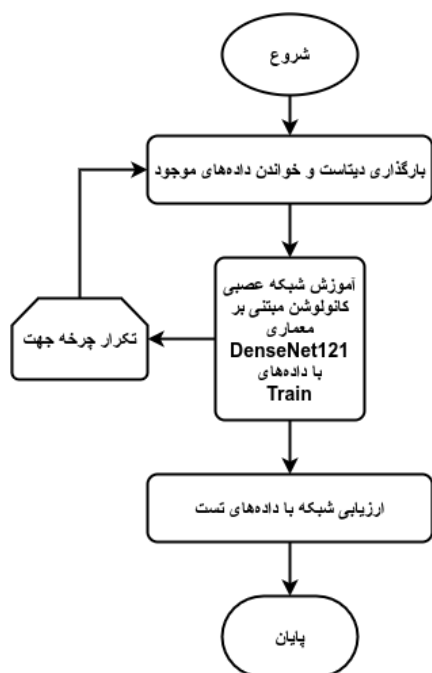
### داده‌ها و روش حل مسئله

در این فصل به معرفی داده‌های مسئله و همچنین معرفی و بررسی کامل مدل پیشنهادی مبتنی بر معماری DenseNet121 می‌پردازیم. همچنین آمارهای مربوط به دیتاست از نظیر تعداد داده و تعداد داده‌های مبتلا به کوید و تعداد داده‌های سالم نیز بحث می‌شود.

#### ۳-۱ چارچوب کاری پروژه

در این پروژه در ابتدا دیتاست مورد نظر ما که SARS-CoV-2 CTScan Dataset است، بارگذاری می‌شود. در این دیتاست دو نوع داده وجود دارد : COVID و Non-COVID، در مرحله اول داده‌ها خوانده شده، تغییر اندازه و نرمال‌سازی می‌شود. سپس با توجه به داده‌ها، دو کلاس اصلی سالم و کوید ۱۹ ایجاد می‌شود و تصاویر به دو دسته Train و Test تقسیم می‌شوند و با شبکه عصبی کانولوشن با معماری DenseNet121 آموزش می‌بیند و همانطور که در تصویر ۳-۱ مشاهده می‌نمایید، شبکه به تعداد دور لازم جهت آموزش داده‌های Train تکرار می‌شود و بعد از هر بار تکرار چرخه روی داده‌های Train، میزان خطا کاهش می‌یابد (این یک چرخه بازگشتی است). در هنگامی که آموزش شبکه با داده‌های Train به پایان رسید، نوبت به اعتبارسنجی شبکه روی داده‌های Test موجود در دیتاست است و نتیجه به صورت طبقه‌بندی به دو حالت کوید ۱۹ و سالم روی داده‌های تست

نمایش داده می‌شود.



این پروژه سه مرحله اساسی دارد :

۱. مرحله بارگذاری دیتاست


۲. مرحله آموزش

۳. طبقه‌بندی و ارزیابی

شکل ۳-۱: چارچوب کاری پروژه

### ۲-۳ داده‌های مورد استفاده در پروژه

در این پروژه ما از دیتاست عکس‌های سی‌تی‌اسکن ریه بیماران در SARSCoV-2 CT Scan Dataset [۱۵] استفاده کردیم که شامل ۲۴۸۲ تصویر سی‌تی‌اسکن ریه است. در این دیتاست دو نوع پوشه با نام‌های COVID شامل ۱۲۵۲ عکس سی‌تی‌اسکن ریه افراد مبتلا به بیماری کوید ۱۹ و Non-COVID شامل ۱۲۳۰ عکس سی‌تی‌اسکن ریه متعلق به افراد سالم وجود دارد. در این مجموعه ۱۹۸۵ تصویر سی‌تی‌اسکن جهت Train (80%) و ۴۹۷ تصویر سی‌تی‌اسکن جهت Test (20%) در نظر می‌گیریم.



شکل ۳-۳: نمونه تصویر در دیتاست با برچسب  $-ve$

شکل ۳-۲: نمونه تصویر در دیتاست با برچسب  $+ve$

### ۳-۳ بررسی مدل پیشنهادی برای حل مسئله

همانطور که در شکل ۳-۱ اشاره شده است، پروژه ما سه مرحله اساسی دارد. در مرحله بارگذاری دیتاست، دیتاست معتبر SARS-CoV-2 که شامل مجموعه‌ای از داده‌ها از تصاویر سی‌تی‌اسکن ریه است، بارگذاری می‌شود. پس از آن، مرحله آموزش خود به چند بخش تقسیم می‌شود:

#### ۱. تغییر اندازه همه تصاویر

در این مرحله کلیه تصاویر با سایزهای مختلف خوانده شده و همه به سایز  $3 \times 64 \times 64$  تغییر پیدا کرده و نرمال‌سازی می‌شوند.

#### ۲. ایجاد دو کلاس اصلی

در این مرحله با توجه به داده‌های موجود در دیتاست، دو کلاس سالم و کوید ۱۹ ایجاد می‌شوند.

#### ۳. تقسیم داده‌ها

در این مرحله داده‌ها تقسیم‌بندی شده و ۸۰٪ برای آموزش و ۲۰٪ برای اعتبارسنجی استفاده می‌شوند که ۱۹۸۵ تصویر سی‌تی‌اسکن ریه جهت آموزش و ۴۹۷ تصویر دیگر جهت اعتبارسنجی به کار می‌رود.

#### ۴. ایجاد مدل اصلی

در این مرحله شبکه عصبی کانولوشن با معماری DenseNet121 جهت آموزش داده‌ها ایجاد می‌شود.

#### ۵. آموزش داده‌های Train

در این مرحله ۱۹۸۵ تصویر مورد نظر با شبکه عصبی کانولوشن مورد نظر و با توجه به وزن‌های مناسب

آموزش می‌بینند. این مرحله بازگشتی به مرحله ۴ است و به تعداد مناسب تکرار می‌شود. در پروژه فعلی من ۵۰ بار تکرار وجود دارد.

پس از مرحله آموزش، مرحله طبقه‌بندی و ارزیابی شبکه با داده‌های Test را داریم. در این مرحله با توجه به نوع تصاویر دیتاست، دو نوع کلاس وجود دارد: کوید ۱۹ و سالم که در پایان، نتیجه خروجی، نوع کلاس یا بیماری را مشخص می‌کند و جهت ارزیابی مدل پیشنهادی معیارهای دقت<sup>۱</sup>، حساسیت<sup>۲</sup> و تشخیص<sup>۳</sup> را به دست می‌آوریم که در فصل چهارم به تفصیل به این قسمت خواهیم پرداخت.

### ۳-۴ شبکه DenseNet121

معماری DenseNet با یک بلوک کانولوشن-ادغام<sup>۴</sup> شروع می‌شود و با یک سری از بلوک متراکم<sup>۵</sup> ادامه می‌یابد و با یک بلوک طبقه‌بندی شامل یک لایه ادغام میانگین جهانی<sup>۶</sup> و یک بلوک متصل کامل<sup>۷</sup> خاتمه می‌یابد. در هر بلوک متراکم، تنسور ورودی از یک سری عملیات درهم‌پیچش<sup>۸</sup> با تعداد فیلترهای ثابت ( $k$ ) عبور می‌کند و نتیجه هر یک از بلوک‌ها با تنسور اصلی مرتبط<sup>۹</sup> می‌شود. بنابراین تعداد نقشه‌های ویژگی<sup>۱۰</sup> تنسور ورودی از رشد حسابی در هر مرحله داخلی بلوک متراکم توسط تعداد عملیات درهم‌پیچش  $k$  برخوردار است. در لایه انتقال تعداد نقشه‌های ویژگی تنسور ورودی به نصف کاهش می‌یابد. در این لایه دو بخش زیر وجود دارد:

لایه درهم‌پیچش  $1 \times 1$  و لایه ادغام میانگین<sup>۱۱</sup>  $2 \times 2$  با گام<sup>۱۲</sup> ۲

در بلوک طبقه‌بندی لایه‌های زیر وجود دارد:

لایه ادغام میانگین جهانی  $7 \times 7$  و لایه متصل کامل با ۱۰۰۰ نورون.

اما DenseNet121 با همین ساختار تعداد ۱۲۱ لایه درهم‌پیچش دارد. [۱۶]

<sup>1</sup>Accuracy

<sup>2</sup>Sensitivity

<sup>3</sup>Specificity

<sup>4</sup>Convolution-Pooling

<sup>5</sup>Dense Block

<sup>6</sup>Global Average Pooling

<sup>7</sup>Fully Connected Block

<sup>8</sup>Convolution


<sup>9</sup>Channel-wise concatenation

<sup>10</sup>Feature Map

<sup>11</sup>Average Pooling


<sup>12</sup>Stride





شکل ۳-۴: ساختار یک بلوک متراکم از DenseNet


هرکدام از لایه‌های شبکه پیچشی متراکم ورودی‌هایی اضافی از همه‌ی لایه‌های قبلی دریافت و نگاشت‌های ویژگی خود را به لایه‌های بعدی منتقل می‌کند. از روش الحاق نیز می‌توان استفاده کرد؛ در این روش، هر لایه دانش جمعی همه‌ی لایه‌های قبلی را دریافت می‌کند.



شکل ۳-۵: ساختار یک بلوک متراکم از DenseNet با نرخ رشد  $k$

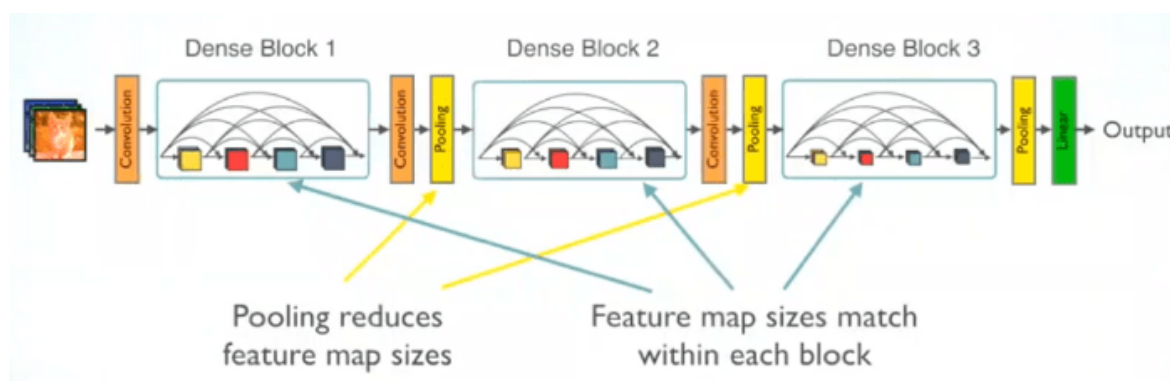
از آنجایی که هر لایه نگاشت‌های ویژگی همه‌ی لایه‌های قبلی را دریافت می‌کند، شبکه می‌تواند باریک‌تر و فشرده‌تر باشد؛ یعنی تعداد کانال‌های کمتری داشته باشد. نرخ رشد  $k$  معیاری است که تعداد کانال‌های اضافه شده در هر لایه را نشان می‌دهد.

بنابراین می‌توان گفت شبکه پیچشی متراکم از نظر محاسباتی و حافظه کارایی بیشتری دارد. شکل ۳-۴ مفهوم روش الحاق طی انتشار رو به جلو را نشان می‌دهد.



شکل ۳-۶: فرایند ادغام طی انتشار رو به جلو

برای هر لایه‌ی تشکیل‌دهنده، تابع پیش-فعال‌سازی BN (Batch Norm) و ReLU و سپس کانولوشن  $3 \times 3$  را اجرا می‌کنیم؛ خروجی این توابع نگاشت‌های ویژگی از  $k$  کانال است که، برای مثال، به منظور تبدیل  $x_0, x_1, x_2, x_3$  به  $x_4$  مورد استفاده قرار می‌گیرند. ایده‌ی زیربنایی این مرحله از Pre-Activation ResNet گرفته شده است.



شکل ۳-۷: شبکه DenseNet با سه بلوک متراکم

لایه درهم‌پیچش  $1 \times 1$  و لایه ادغام میانگین  $2 \times 2$  با گام ۲ که بعد از آن می‌آید به عنوان لایه‌های گذار بین دو بلوک متراکم همجوار استفاده می‌شوند. نگاشت‌های ویژگی درون یک بلوک متراکم هم‌اندازه هستند تا بتوان عملیات الحاق را به راحتی روی آن‌ها اجرا کرد. در انتهای آخرین بلوک متراکم، یک تابع سراسری میانگین تجمع اجرا می‌شود.

## فصل چهارم

### تجزیه و تحلیل نتایج

در این فصل به ارزیابی مدل در برابر معیارهای مختلف می‌پردازیم و دقت‌های بدست آمده توسط مدل را روی داده‌ی تست گزارش می‌کنیم. لازم به ذکر است که برای این مسئله ۱۹۸۵ تصویر برای عملیات آموزش و ۴۹۷ تصویر برای اعتبارسنجی استفاده شده است.

#### ۴-۱ معرفی معیارهای مختلف

شاخص‌های ارزیابی به شرح زیر است :

TP : موارد مثبت که به درستی طبقه‌بندی شده‌اند  
TN : موارد منفی که به درستی طبقه‌بندی شده‌اند  
FN : موارد مثبت که به طور نادرست طبقه‌بندی شده‌اند  
FP : موارد منفی که به طور نادرست طبقه‌بندی شده‌اند

دقت<sup>۱</sup> = این معیار بیانگر دقت کلی طبقه‌بندی می‌باشد و بیانگر نرخ طبقه‌بندی صحیح می‌باشد. همانطور که در رابطه ۴-۱ مشاهده می‌نمایید.

$$Accuracy = \frac{TP + TN}{TP + FN + TN + FP} \quad (4-1)$$

---

<sup>1</sup> Accuracy

حساسیت<sup>۱</sup> = این معیار بیانگر حساسیت کلی طبقه‌بندی می‌باشد و حاصل تقسیم موارد مثبت واقعی به حاصل جمع موارد مثبت واقعی و موارد منفی کاذب است. همانطور که در رابطه ۲-۴ مشاهده می‌نمایید.

$$Sensitivity = \frac{TP}{TP + FN} \quad (2-4)$$

خاصیت<sup>۲</sup> = خاصیت حاصل تقسیم موارد منفی واقعی به حاصل جمع موارد منفی واقعی و مثبت کاذب است. همانطور که در رابطه ۳-۴ مشاهده می‌نمایید.


$$Specificity = \frac{TN}{TN + FP} \quad (3-4)$$

## ۲-۴ شبیه‌سازی مدل

در این بخش به ارزیابی طرح پیشنهادی یعنی تشخیص بیماری کوید ۱۹ با استفاده از شبکه عصبی کانولوشن مبتنی بر معماری DenseNet121 می‌پردازیم، در این قسمت مدل پیشنهادی را در پایتون پیاده‌سازی و شبیه‌سازی می‌کنیم. مقادیر مناسب پارامترهای یادگیری شبکه از طریق آزمایشات متعدد تعیین می‌شود. نتایج با اجرای شبیه‌سازی در محیط پایتون 3.8 و در لپتاپ با پردازنده Corei7 و حافظه تصادفی ۸ گیگابایت به دست آمده است.

### ۱-۲-۴ نمایش دیاگرام دقت و خطای شبکه روی داده‌ها

همانطور که در تحقیقات قبلی دانشمندان به اثبات رسیده بود، شبکه عصبی کانولوشن با معماری DenseNet121 یکی از بهترین شبکه‌های تشخیصی است و از بین ۲۴۸۲ داده دیتاست و با ۵۰ بار تکرار، دقت 90% و خطای زیر 7% را به همراه دارد و در شکل ۱-۲-۴ دقت شبکه را مشاهده می‌نمایید.



شکل ۱-۴: نمایش دیاگرام دقت شبکه روی داده‌ها

<sup>1</sup>Sensitivity


<sup>2</sup>Specificity

#### ۲-۲-۴ طبقه‌بندی و ارزیابی

جهت اعتبارسنجی، ارزیابی و به دست آوردن پارامترهای دقت، حساسیت و تشخیص از ماتریس درهم‌ریختگی استفاده می‌شود. این ماتریس اطلاعاتی را در مورد صحت طبقه‌بندی شامل دو کلاس COVID و Non Covid در دو بخش واقعی و پیش‌بینی شده به ما ارائه می‌نماید. ماتریس درهم‌ریختگی را در شکل ۲-۲-۴ و جدول ۲-۲-۴ مشاهده می‌نمایید.

جدول ۱-۴: جدول درهم‌ریختگی

کلاس‌های پیش‌بینی شده			
بیمار	سالم	دیتاست	
۲۵۸	۱۶		
۱۹	۲۰۴		



شکل ۲-۴: ماتریس درهم‌ریختگی و کلاس‌بندی

نتایج حاصل از ماتریس درهم‌ریختگی، دقت 92.96%، حساسیت 91% و تشخیص 94% را در اجرای مدل به دنبال داشت.

## فصل پنجم

### نتیجه‌گیری و جمع‌بندی

با توجه به این که بیماری کرونا تبدیل به یکی از عوامل اساسی مرگ و میر در قرن حاضر شده است ، بر همین اساس یک شبکه تخصصی می‌تواند روش تشخیصی مناسبی جهت تشخیص زودهنگام بیماری محسوب شود. در این پروژه با استفاده از شبکه عصبی کانولوشن با معماری DenseNet121 و قدرت آن در کلاسیفیکیشن و تشخیص بیماری‌ها از ۲۴۸۲ تصویر سی‌تی‌اسکن موجود در دیتاست SARS-CoV-2 به صورت 80% جهت آموزش و 20% جهت تست و ارزش‌گذاری استفاده شد که در نهایت دقت 92.96% ، حساسیت 91% و تشخیص 94% را به دنبال داشت و نشان داد استفاده از این شبکه روشی مناسب جهت تشخیص زودهنگام بیماری کوید ۱۹ است. بنابراین این شبکه پیشنهادی قابل گسترش و بهبود است و می‌تواند به عنوان اپلیکیشن ساخته شده و در اختیار پزشکان و کادر پزشکی جهت تشخیص بیماری‌های کرونا قرار گیرد.

## مراجع

- [1] J. Chen, L. Wu, J. Zhang, L. Zhang, D. Gong, Y. Zhao, S. Hu, Y. Wang, X. Hu, B. Zheng et al., *Deep learning-based model for detecting 2019 novel coronavirus pneumonia on high-resolution computed tomography: a prospective study*, medRxiv, 2020.
- [2] D. Wang, B. Hu, C. Hu, F. Zhu, X. Liu, J. Zhang, B. Wang, H. Xiang, Z. Cheng, Y. Xiong et al., *Clinical characteristics of 138 hospitalized patients with 2019 novel coronavirus–infected pneumonia in wuhan, china*, Jama, 2020
- [3] K. G. Udeshani, *Statistical Feature-based Neural Network Approach for the Detection of Lung Cancer in Chest X-Ray Images*, Int. J. Image Process., vol. 5, no. 4, pp. 425–434, 2011
- [4] Oquab M, Bottou L, Laptev I, Sivic J, editors. *Learning and transferring mid-level image representations using convolutional neural networks*. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition; 2014.
- [5] Szegedy C, Liu W, Jia Y, Sermanet P, Reed S, Anguelov D, et al., editors. *Going deeper with convolutions*. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition; 2015.
- [6] Joseph Bullock, Katherine Hoffmann Pham, and Miguel Luengo-Oroz. 2020. Mapping the Landscape of Artificial Intelligence Applications against COVID-19 arXiv:2003.11336 (2020).

- [7] Tao Ai, Zhenlu Yang, Hongyan Hou, Chenao Zhan, and Liming Xia. 2020. Correlation of chest CT and RT-PCR testing in coronavirus disease 2019 (COVID-19) in China: a report of 1014 cases. *Radiology* (2020), 200642.
- [8] Kate Madden Yee. 2020. X-ray may be missing COVID cases found with CT. *Korean Journal of Radiology* (2020), 1–7.
- [9] Yicheng Fang, Huangqi Zhang, Jicheng Xie, Minjie Lin, Lingjun Ying, Peipei Pang, and Wenbin Ji. 2020. Sensitivity of chest CT for COVID-19: comparison to RT-PCR. *Radiology* (2020), 200432.
- [10] J. Zhao, Y. Zhang, X. He X., and P. Xie, *Covid-ct-dataset: a ct scan dataset about covid-19*, “arXiv preprint arXiv:2003.13865, 2020.
- [11] M. Loey, F. Smarandache, and N. E. M. Khalifa, *A deep transfer learning model with classical data augmentation and cgan to detect covid-19 from chest ct radiography digital images*, Preprints, 2020.
- [12] O. Gozes, M. F.-Adar, H. Greenspan, P. D. Browning, and H. Zhang, et al., *Rapid AI development cycle for the coronavirus (COVID-19) pandemic: initial results for automated Detection & patient monitoring using deep learning CT image analysis*, arXiv preprint arXiv:2003.05037, 2020.
- [13] Y.-H. Wu, S.-H. Gao, J. Mei, J. Xu, and D.-P. Fan, et al., *JCS: An explainable COVID-19 diagnosis system by joint classification and segmentation*, arXiv:2004.07054v1, April 2020 .
- [14] Ahuja, Sakshi, et al. *Deep transfer learning-based automated detection of COVID-19 from lung CT scan slices*. (2020).
- [15] <https://www.kaggle.com/plameneduardo/sarscov2-ctscan-dataset?select=non-COVID>
- [16] Huang, Gao, et al. *Densely connected convolutional networks*. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017